# CURSO PYTHON

MÓDULO 2

# Introdução ao Pandas

**Pandas é a principal biblioteca Python para análise e manipulação de dados. Com ela é possível carregar, limpar, transformar e explorar dados de forma simples e eficiente.**

**Ela é amplamente utilizada em ciência de dados, machine learning e análise estatística.**

```python
import pandas as pd
import numpy as np

# Estruturas principais:
# Series  → coluna de dados (1D)
# DataFrame → tabela de dados (2D)

s = pd.Series([10, 20, 30])
print(s)
```

# 1. Criando um DataFrame

**Um DataFrame pode ser criado a partir de um arquivo CSV usando pd.read_csv().**

**Para aumentar o volume de dados, podemos concatenar o dataset com ele mesmo usando pd.concat().**

```
import pandas as pd

data = pd.read_csv(
  'dataset_desempenho_escolar.csv'
)
df = pd.DataFrame(data)

# Duplicar o dataset
df_maior = pd.concat([df, df],
                     ignore_index=True)
print(df_maior.shape)
```

**SAÍDA = (20, 3)**

# 2. Limpeza de Dados

## Removendo valores negativos

- Dados reais frequentemente contêm erros
- Valores negativos em notas ou frequência são inválidos
- Filtramos linhas onde todos os números são ≥ 0

```
# Simulando dado corrompido
df.loc[1, 'frequencia'] = -22

# Remover valores negativos
df_clean = df[
  (df.select_dtypes(
     include=['number']
  ) >= 0).all(axis=1)
]
df_clean.head()
```

# 3. Transformação de Dados

## Criando nova coluna

**Podemos criar novas colunas aplicando operações sobre colunas existentes.**

**A nova coluna multiplicacao_calc é o produto entre nota e frequência de cada aluno.**

```
# Criar coluna multiplicação
df_clean['multiplicacao_calc'] = (
  df_clean['nota']
  * df_clean['frequencia']
)

# Criar coluna divisão
df_clean['divisao_calc'] = (
  df_clean['nota']
  / df_clean['frequencia']
)
df_clean.head()
```

# 4. Estatística Descritiva

- **describe() → resumo estatístico completo**
- **mean() → média dos valores**
- **median() → mediana**
- **std() → desvio padrão**

```
# Resumo geral
df_clean.describe()

# Média de notas
media = df_clean['nota'].mean()
print(media)

# Mediana
df_clean['nota'].median()

# Desvio padrão
df_clean['nota'].std()
```

**média ≈ 7.60**

# 5. Top 5 Notas Mais Altas

**sort_values() ordena o DataFrame por uma coluna. Combinado com head(5), obtemos os 5 melhores alunos.**

**ascending=False garante que os maiores valores vêm primeiro.**

```
# Filtrar nota máxima
nota_max = df_clean['nota'].max()
df_clean[df_clean['nota'] == nota_max]

# Top 5 notas mais altas
top5 = df_clean.sort_values(
  by='nota',
  ascending=False
).head(5)
print(top5[['nome', 'nota']])
```

**SAÍDA = Julia 10.0 | Elisa 9.5 …**

# 6. Boas Práticas com Pandas

## Organização

- sempre use ignore_index=True ao concatenar
- evite modificar o DataFrame original
- nomeie colunas calculadas de forma descritiva

**Ruim**

```
df2 = pd.concat([df, df])
```

**Melhor**

```
df_maior = pd.concat(
  [df, df], ignore_index=True
)
```